

Laboratorio 1: Series de Tiempo

Ingreso de viajeros internacionales a Guatemala (2009 – junio 2026)

AVANCE — Análisis Exploratorio y Análisis Preliminar de Series de Tiempo

Entrega de avance: 23 de julio de 2026

Nota: este documento corresponde al avance solicitado (análisis exploratorio general y análisis preliminar de al menos dos series de tiempo). La estacionariedad formal, el modelado ARIMA/Prophet/Holt-Winters, las predicciones y el análisis comparativo completo se desarrollarán en el documento final (entrega del 26 de julio de 2026), siguiendo la estructura de la guía de laboratorio.

Nota de la fuente: los datos son de uso exclusivamente académico; no corresponden a cifras oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

0. Descripción del conjunto de datos

El conjunto de datos contiene el ingreso mensual de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 (210 meses consecutivos, sin huecos), en formato largo: cada fila es una combinación única de año, mes, vía de ingreso, frontera, país/agrupación de residencia y tipo de viajero, con la cantidad correspondiente en la columna **Viajero**. El archivo contiene **161,036 registros** y 13 columnas.

La fuente combina tres tramos con metodologías distintas: (1) 2009–2020, respaldos históricos; (2) 2021–2022, entrega del IGM con caracterización; (3) 2023–jun. 2026, sistema depurado del INGUAT. Esto genera dos quiebres relevantes para el análisis de series de tiempo:

- **Quiebre por pandemia (2020):** colapso de viajeros desde marzo de 2020, piso en 2020–2021 (26% y 27% del nivel de 2019 en la serie comparable) y recuperación gradual desde 2022.
- **Quiebre metodológico 2022→2023:** el sistema depurado excluye a los viajeros no turísticos de alta frecuencia (comercio fronterizo, tránsito) de la categoría "Viajero", y desde 2023 la columna "País" pasa de reportar país individual (232 valores distintos hasta 2022) a agrupaciones de mercado (26 grupos). Por esto, la categoría "Viajero" cae de 1.06M en 2022 a 0.33M en 2023 sin que exista una caída real de tránsito fronterizo; para series comparables en todo el rango el enunciado recomienda usar Turista + Excursionista.

Adicionalmente: la vía Marítima pierde detalle de registro desde 2017; los decimales en "Viajero" en 2021-2022 corresponden a estimaciones expandidas de encuesta, no conteos exactos; y el año 2026 solo cubre de enero a junio.

1. Análisis exploratorio

1.1 Comportamiento temporal del número de viajeros




Figura 1. Total mensual de viajeros internacionales, todas las categorías (2009–2026).

La serie total muestra una tendencia creciente sostenida entre 2009 y 2019 (con estacionalidad marcada), una caída abrupta en marzo de 2020 y un piso prolongado durante 2020–2021 producto del cierre de fronteras por la pandemia de COVID-19, y una recuperación progresiva a partir de 2022. La línea discontinua naranja marca el quiebre metodológico de 2023: a partir de ese punto el nivel de la serie total ya no es estrictamente comparable con los años anteriores debido al cambio en la definición de "Viajero" y en la granularidad de país, aunque el patrón visual de recuperación pos-pandemia es consistente con fuentes externas de turismo.

regional.




Figura 2. Serie mensual de Turista + Excursionista (comparable en todo el período).

Al aislar Turista + Excursionista —la combinación recomendada por el enunciado para comparabilidad plena— el quiebre metodológico de 2023 deja de ser visible como salto de nivel, y el patrón pandemia/recuperación queda igual de claro. Esta será la serie de referencia para discutir el impacto "real" de la pandemia en el turismo, mientras que la serie total (obligatoria) se usará para el volumen agregado de ingreso migratorio.

1.2 Países con mayor cantidad de viajeros



Figura 3. Top 15 países/agrupaciones de residencia por viajeros acumulados (2009–2026).

País / Agrupación	Viajeros acumulados	% del total
-------------------	---------------------	-------------

El Salvador	16,213,975	31.0%
Guatemala	14,792,331	28.3%
Estados Unidos de América	7,047,843	13.5%
Honduras	2,788,233	5.3%
México	1,808,946	3.5%
Belice	1,328,256	2.5%
Nicaragua	1,164,343	2.2%
Cruceistas	1,078,372	2.1%
Costa Rica	882,180	1.7%
Colombia	561,035	1.1%

El Salvador y Guatemala concentran conjuntamente el 59.3% del total histórico, lo que confirma el dominio estructural de la movilidad terrestre centroamericana sobre el turismo internacional de larga distancia.

Hallazgo relevante: "Guatemala" aparece como segundo país de residencia (14.8M, 28.3%), a pesar de tratarse del país anfitrión. Al desagregar, el 77.3% de estos registros son "Turista" y provienen mayoritariamente de La Aurora (aeropuerto internacional) y de fronteras terrestres — es decir, corresponde principalmente a **residentes guatemaltecos que regresan del extranjero** (posible turismo de visita a familiares, VFR), no a turismo extranjero. Para el análisis de países se documenta este caso, y se recomienda tenerlo presente al interpretar la serie de "Guatemala" como serie de comparación, distinta en naturaleza a la de un mercado emisor extranjero real.

1.3 Regiones con mayor cantidad de viajeros




Figura 4. Viajeros acumulados por región (variable "Región dos"), 2009–2026.

América del Centro concentra el 71.5% del total acumulado, seguida de América del Norte (17.9%) y Europa (4.3%). El resto de regiones (Sudamérica y el Caribe, Asia, Oceanía, Oriente Medio) aportan en conjunto 6.3%. Se detectaron 13 registros (0.0081% del total) con el valor "0" en "Región dos" — un valor residual de catálogo

sin agrupación asignada durante 2022, discutido en la sección 1.5 de calidad de datos.

1.4 Vías de ingreso y fronteras más utilizadas




Figura 5. Viajeros acumulados por vía de ingreso (izq.) y top 10 fronteras (der.).

La vía Terrestre domina con 61.2% del total histórico, seguida de la vía Aérea (36.5%); la vía Marítima representa apenas 2.4%, coherente con la pérdida de detalle de registro desde 2017 señalada en las notas de la fuente. A nivel de frontera puntual, el Aeropuerto La Aurora concentra el 36.4% del total (toda la vía aérea), seguido de Valle Nuevo (20.5%, frontera con El Salvador) y San Cristóbal (10.3%, frontera con Honduras) — ambas coherentes con el peso de El Salvador y Honduras entre los principales países emisores.

1.5 Valores faltantes, duplicados y valores atípicos

- **Valores faltantes:** 0 en las 13 columnas — el conjunto de datos está completo.
- **Filas duplicadas exactas** (todas las columnas): 0.
- **Cuasi-duplicados aparentes:** al agrupar por Año, Mes, Vía, Frontera, País y Tipo de Viajero (sin incluir "Agrupación Residencia") aparecen 20 combinaciones repetidas; al inspeccionarlas se confirma que corresponden a subcategorías legítimas y distintas de "Agrupación Residencia" dentro del mismo país (p. ej. "Colombia" vs. "Otros Suramérica" dentro del país "Colombia") — no son errores de carga, sino mayor granularidad de esa columna.
- **Valores en cero:** 54 registros (0.03%) — plausibles dado que corresponden a combinaciones de categorías con muy baja frecuencia (p. ej. un país/vía/mes puntual sin viajeros ese mes).
- **Valores negativos:** 0.
- **Atípicos a nivel de fila** (regla de Tukey, $1.5 \times \text{RIC}$ sobre "Viajero"): el umbral superior es 94.2 viajeros por registro y el 16.4% de las filas lo supera. Esto es un artefacto esperado de una variable de conteo extremadamente sesgada a la derecha por el diseño mismo del dataset (categorías con miles de combinaciones posibles de país/frontera/tipo, la mayoría con volúmenes pequeños y unas pocas —como La Aurora/vía Aérea o Valle Nuevo/vía Terrestre— con volúmenes muy altos). No se interpretan como errores de captura; el análisis de atípicos relevante para series de tiempo se hará sobre las series agregadas mensuales (sección 1.6 y 2), donde el evento atípico dominante es el colapso de viajeros por la pandemia en 2020.
- **Quebres estructurales en volumen de registros por año** (no en "Viajero", sino en la cantidad de filas): de ~10,213–12,595 registros/año entre 2009-2019, cae a 4,375 en 2020 y 6,523–7,323 en 2021-2022

(menos combinaciones activas por la pandemia), y baja de nuevo a ~4,660–5,148 registros/año desde 2023 por el cambio de país individual a agrupación de mercado. Es importante no confundir este quiebre de granularidad con un cambio real en el volumen de viajeros.

1.6 Estadísticas descriptivas




Figura 6. Distribución de "Viajero" por registro (log) y total acumulado por tipo de viajero.

Estadístico	Valor (viajeros por registro)
Conteo	161,036
Media	324.70
Desv. estándar	2,387.75
Mínimo	0.00
Percentil 25	2.00
Mediana	7.00
Percentil 75	38.89
Máximo	92,336.04 (Belice, Melchor de Mencos, tipo Viajero, 2017-08)

La distribución de "Viajero" por registro es fuertemente asimétrica a la derecha (media muy superior a la mediana), típica de datos de conteo desagregados en muchas categorías. A nivel de tipo de viajero, Turista concentra 72.0% del total histórico, Excursionista 17.3%, Viajero (tránsito/comercio fronterizo de alta frecuencia) 8.6% y Cruceristas 2.1% — coherente con la recomendación del enunciado de usar Turista + Excursionista (89.3% del total) como medida comparable de flujo turístico en todo el período.

2. División en entrenamiento y prueba

Dado que se trabaja con series de tiempo, la división se realizó de forma **cronológica** (no aleatoria), cortando el eje temporal en el mes que deja aproximadamente 70% de los meses en entrenamiento y 30% en prueba, de forma que el conjunto de prueba siempre sea posterior en el tiempo al de entrenamiento.

Conjunto	Rango de fechas	N.º de meses	% de meses	Filas del dataset
Entrenamiento	2009-01 a 2021-03	147	70.0%	131,442 (81.6%)
Prueba	2021-04 a 2026-06	63	30.0%	29,594 (18.4%)

La proporción de *meses* es exactamente 70/30 por construcción. La proporción de *filas* del dataset difiere (81.6% / 18.4%) porque, como se documentó en 1.5, el tramo 2009–2022 tiene mayor granularidad de país (más filas por mes) que el tramo 2023 en adelante; esto no afecta la validez de la partición temporal, solo refleja el cambio de metodología de la fuente. Todas las series de tiempo del punto 3 se construyen exclusivamente a partir del conjunto de entrenamiento (2009-01 a 2021-03).

3. Series de tiempo construidas (a partir de entrenamiento)

Se construyó la serie obligatoria (total mensual) y se seleccionaron dos categorías de análisis: **(i) Vías de ingreso** (Aérea, Terrestre y Marítima) y **(ii) Países de residencia**, tomando el top 3 según el acumulado de todo el período de estudio 2009–2026 (no solo entrenamiento): El Salvador, Guatemala y Estados Unidos de América. En total se obtienen $1 + 3 + 3 = 7$ series mensuales.

Nota metodológica: todas las series se reindexaron contra el rango fijo de 147 meses de entrenamiento (no contra el propio primer/último dato de cada subserie), de forma que los meses sin ningún registro se reflejen como 0 en vez de recortar la serie. Esto fue clave para la vía Marítima, que no tiene ningún registro durante 12 meses consecutivos por el cierre de fronteras marítimas: sin este ajuste la serie parecía terminar antes de tiempo.

4. Análisis preliminar de las series

A continuación se presenta el análisis preliminar (inicio/fin/frecuencia, gráfico, descomposición y una primera lectura de estacionariedad con ACF y la prueba de Dickey-Fuller Aumentada) para la serie obligatoria y para las seis series de las dos categorías seleccionadas. El análisis formal de estacionariedad (transformaciones, número de diferenciaciones) y el modelado ARIMA/Prophet/Holt-Winters se completan en el documento final.

Total mensual de viajeros internacionales

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 237,120.9 **Desv. estándar:** 101,886.5 **Mín-Máx:** 9,779 – 515,820.4




Figura. Total mensual de viajeros internacionales — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Muestra tendencia creciente 2009-2019, colapso pandémico en 2020 y recuperación parcial hacia el corte de entrenamiento (mar-2021). La descomposición aditiva evidencia un componente de tendencia claramente no constante y una estacionalidad anual regular (picos en jul-ago y dic, típicos de temporada alta). El residuo muestra mayor dispersión durante 2020, coherente con la ruptura estructural de la pandemia.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -1.970, p-valor = 0.2998 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

Vía de ingreso: Aérea

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 89,141.3 **Desv. estándar:** 29,412.5 **Mín-Máx:** 489 – 157,842.0




Figura. Vía de ingreso: Aérea — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Tendencia creciente sostenida hasta 2019 y estacionalidad anual visible (picos de temporada alta). Cae prácticamente a cero en abr-2020 por el cierre del Aeropuerto La Aurora al tráfico de pasajeros.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -2.364, p-valor = 0.1522 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

Vía de ingreso: Terrestre

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 139,988.5 **Desv. estándar:** 72,323.9 **Mín-Máx:** 5,715 – 348,626.4



Figura. Vía de ingreso: Terrestre — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Es la serie de mayor volumen y mayor variabilidad absoluta (desv. estándar 72,323.9). Conserva un piso positivo incluso en pandemia, reflejando que el cruce terrestre nunca se cerró por completo (comercio y residentes fronterizos).

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -1.873, p-valor = 0.3451 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

Vía de ingreso: Marítima

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 7,991.2 **Desv. estándar:** 6,934.3 **Mín-Máx:** 0 – 29,506.0




Figura. Vía de ingreso: Marítima — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Serie de menor volumen y con un tramo de 12 meses consecutivos exactamente en cero por el cierre de fronteras marítimas, el evento atípico más marcado de las 7 series (16 meses en cero en total, contando algunos previos a la pandemia). Su patrón estacional es menos regular que el de las otras dos vías.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -0.989, p-valor = 0.7571 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

País de residencia: El Salvador

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 61,502.0 **Desv. estándar:** 33,698.0 **Mín-Máx:** 0 – 165,263.0




Figura. País de residencia: El Salvador — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Máximo emisor individual; sigue de cerca el patrón agregado de la vía Terrestre, con estacionalidad ligada a fines de semana largos y temporada de fin de año en la región.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -1.781, p-valor = 0.3901 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

País de residencia: Guatemala

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 86,951.8 **Desv. estándar:** 40,005.6 **Mín-Máx:** 9,779 – 207,097.0



Figura. País de residencia: Guatemala — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Segunda serie en volumen; como se documentó en 1.2, mezcla flujo aéreo y terrestre y probablemente corresponde en su mayoría a residentes guatemaltecos que regresan del extranjero, por lo que su lectura como "mercado emisor" debe hacerse con cautela.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -2.091, p-valor = 0.2481 → no se rechaza H_0 (no estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

País de residencia: Estados Unidos de América

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 27,955.1 **Desv. estándar:** 11,062.9 **Mín-Máx:** 0 – 54,990.0




Figura. País de residencia: Estados Unidos de América — serie, tendencia, estacionalidad y residuo (train).




Figura. Función de autocorrelación (ACF, 36 rezagos).

Es la única de las 7 series cuya prueba ADF preliminar rechaza la hipótesis nula al 5% ($p = 0.0249$), es decir, el único caso donde el resultado preliminar apunta a estacionariedad en media sin diferenciar; aun así se observa un quiebre de nivel claro en 2020 que debe evaluarse con más detalle en el documento final.

Prueba ADF preliminar (sobre el nivel, sin diferenciar): estadístico = -3.122, p-valor = 0.0249 → se rechaza H_0 (estacionaria en media). La ACF decae lentamente y con un patrón oscilante de periodo aproximadamente anual, consistente con la presencia de tendencia y estacionalidad — ambos síntomas típicos de no estacionariedad en media, que en el documento final se abordarán con diferenciación regular y/o estacional según corresponda, además de confirmar la necesidad (o no) de una transformación (p. ej. logarítmica) para estabilizar la varianza.

5. Próximos pasos (documento final — 26 de julio de 2026)

- Completar la construcción de las 7 series también para el conjunto de prueba, para poder evaluar predicciones fuera de muestra.
- Determinar formalmente la estacionariedad en varianza (transformación Box-Cox/log si corresponde) y en media (número de diferenciaciones regulares y estacionales) para cada una de las 7 series.
- Seleccionar p , d , q (y componente estacional P , D , Q , s si aplica) con base en ACF/PACF, contrastar con `auto_arima`/`auto.arima`, y ajustar varios modelos ARIMA por serie, comparando residuos, AIC y BIC.
- Ajustar y comparar modelos Prophet, Holt-Winters, suavizamiento exponencial y seasonal naive frente a los modelos ARIMA.
- Generar predicciones sobre el conjunto de prueba y comparar todos los modelos con MAE, RMSE, AIC y BIC para seleccionar el mejor modelo por serie.
- Desarrollar el análisis comparativo entre las series de cada categoría (estacionalidad, tendencia, volatilidad, impacto de la pandemia) y los hallazgos generales orientados a la toma de decisiones del INGUAT.