

Universidad del Valle de Guatemala
Facultad de Ingeniería — Departamento de Ciencias de la Computación
CC3084 — Data Science | Semestre II — 2026 | Sección 20

Laboratorio 1: Series de Tiempo

Ingreso de viajeros internacionales a Guatemala (2009 – junio 2026)

Diego López · Nelson Escalante · Roberto Nájera

Julio de 2026

0. Descripción del conjunto de datos

Ingreso mensual de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 (210 meses consecutivos, sin huecos). Formato largo: cada fila combina año, mes, vía de ingreso, frontera, país de residencia y tipo de viajero, con la cantidad en la columna **Viajero**. 161,036 registros y 13 columnas.

La fuente combina tres tramos con metodologías distintas (2009–2020 respaldos históricos, 2021–2022 entrega del IGM, 2023–2026 sistema depurado del INGUAT), lo que produce dos quiebres:

- **Pandemia (2020):** caída desde marzo de 2020, con 26% y 27% del nivel de 2019 en la serie comparable, y recuperación desde 2022.
- **Metodológico (2023):** se excluye a los viajeros no turísticos de alta frecuencia de la categoría "Viajero", que cae de 1.06M a 0.33M sin caída real de tránsito. La columna "País" pasa de 232 países individuales a 26 agrupaciones de mercado. Para comparar todo el rango se usa Turista + Excursionista.

Además: la vía Marítima pierde detalle de registro desde 2017, los decimales de 2021-2022 son estimaciones de encuesta, y 2026 solo cubre enero a junio.

1. Análisis exploratorio

1.1 Comportamiento temporal del número de viajeros




Figura 1. Total mensual de viajeros internacionales, todas las categorías (2009–2026).

Tendencia creciente y estacionalidad marcada entre 2009 y 2019, caída abrupta en marzo de 2020, piso durante 2020–2021 y recuperación desde 2022. La línea naranja marca el quiebre metodológico de 2023: a partir de ahí el nivel de la serie total no es comparable con los años previos.




Figura 2. Serie mensual de Turista + Excursionista (comparable en todo el período).

Al aislar Turista + Excursionista el quiebre de 2023 desaparece como salto de nivel y el patrón pandemia/recuperación se mantiene. Esta es la serie de referencia para el impacto real en turismo; la serie total se usa para el volumen agregado de ingreso migratorio.

1.2 Países con mayor cantidad de viajeros



Figura 3. Top 15 países/agrupaciones de residencia por viajeros acumulados (2009–2026).

País / Agrupación	Viajeros acumulados	% del total
El Salvador	16,213,975	31.0%
Guatemala	14,792,331	28.3%

Estados Unidos de América	7,047,843	13.5%
Honduras	2,788,233	5.3%
México	1,808,946	3.5%
Belice	1,328,256	2.5%
Nicaragua	1,164,343	2.2%
Cruceistas	1,078,372	2.1%
Costa Rica	882,180	1.7%
Colombia	561,035	1.1%

El Salvador y Guatemala concentran el 59.3% del total histórico: domina la movilidad terrestre centroamericana sobre el turismo de larga distancia.

1.3 Regiones con mayor cantidad de viajeros




Figura 4. Viajeros acumulados por región (variable "Región dos"), 2009–2026.

América del Centro concentra el 71.5%, América del Norte 17.9% y Europa 4.3%; el resto de regiones aporta 6.3%. Hay 13 registros (0.0081%) con valor "0" en "Región dos", residuo de catálogo sin agrupación asignada en 2022.

1.4 Vías de ingreso y fronteras más utilizadas




Figura 5. Viajeros acumulados por vía de ingreso (izq.) y top 10 fronteras (der.).

Terrestre domina con 61.2%, seguida de Aérea (36.5%) y Marítima (2.4%, coherente con su pérdida de registro desde 2017). Por frontera, el aeropuerto La Aurora concentra el 36.4% (toda la vía aérea), seguido de Valle Nuevo (20.5%, El Salvador) y San Cristóbal (10.3%, Honduras), consistente con el peso de esos dos mercados.

1.5 Valores faltantes, duplicados y valores atípicos

- **Valores faltantes:** 0 en las 13 columnas — el conjunto de datos está completo.
- **Filas duplicadas exactas** (todas las columnas): 0.
- **Cuasi-duplicados:** 20 combinaciones repetidas al agrupar sin "Agrupación Residencia". Son subcategorías legítimas de esa columna dentro de un mismo país, no errores de carga.
- **Valores en cero:** 54 registros (0.03%), en combinaciones de categorías de baja frecuencia.
- **Valores negativos:** 0.
- **Atípicos por fila** (Tukey, $1.5 \times \text{RIC}$): umbral superior 94.2 viajeros y 16.4% de las filas lo supera. Es esperable en una variable de conteo desagregada en miles de categorías, la mayoría de volumen bajo. No se tratan como errores: el atípico relevante para series de tiempo es el colapso de 2020, visible en las series agregadas.
- **Quiebre en el volumen de registros** (filas, no viajeros): de ~10,213–12,595 al año entre 2009-2019, cae a 4,375 en 2020 y a ~4,660–5,148 desde 2023 por el cambio a agrupación de mercado. No confundir con un cambio real de volumen.

1.6 Estadísticas descriptivas




Figura 6. Distribución de "Viajero" por registro (log) y total acumulado por tipo de viajero.

Estadístico	Valor (viajeros por registro)
Conteo	161,036
Media	324.70
Desv. estándar	2,387.75
Mínimo	0.00
Percentil 25	2.00
Mediana	7.00
Percentil 75	38.89
Máximo	92,336.04 (Belize, Melchor de Mencos, tipo Viajero, 2017-08)

La distribución por registro es fuertemente asimétrica a la derecha (media muy superior a la mediana), típica de conteos desagregados. Por tipo de viajero: Turista 72.0%, Excursionista 17.3%, Viajero 8.6% y Cruceristas 2.1%. Turista + Excursionista suman 89.3%, la medida comparable en todo el período.

1.7 Comportamiento de cada serie durante y después de la pandemia

Las series de modelado terminan en 2021-03, así que la recuperación posterior no se ve en ellas. Estas figuras las muestran sobre los 210 meses del período, con el tramo de entrenamiento sombreado. Son solo exploratorias: el modelado y la predicción usan únicamente entrenamiento.




Figura. Total mensual de viajeros internacionales — período completo (210 meses).




Figura. Vía de ingreso: Aérea — período completo (210 meses).




Figura. Vía de ingreso: Terrestre — período completo (210 meses).




Figura. Vía de ingreso: Marítima — período completo (210 meses).




Figura. País de residencia: El Salvador — periodo completo (210 meses).




Figura. País de residencia: Guatemala — periodo completo (210 meses).




Figura. País de residencia: Estados Unidos de América — periodo completo (210 meses).

Hay tres comportamientos distintos tras la pandemia. La Aérea se recupera con más fuerza y supera su nivel pre-pandemia. La Terrestre mantuvo un piso positivo en 2020 y se recupera de forma más plana. La Marítima no vuelve a los niveles de 2009-2016. En la serie total se ve el salto de nivel de 2023.

2. División en entrenamiento y prueba

La división es **cronológica**, no aleatoria: el corte deja ~70% de los meses en entrenamiento y 30% en prueba, de modo que la prueba siempre sea posterior en el tiempo.

Conjunto	Rango de fechas	N.º de meses	% de meses	Filas del dataset
Entrenamiento	2009-01 a 2021-03	147	70.0%	131,442 (81.6%)
Prueba	2021-04 a 2026-06	63	30.0%	29,594 (18.4%)

La proporción de meses es 70/30 por construcción. La de filas difiere (81.6% / 18.4%) porque el tramo 2009–2022 tiene más granularidad de país; no afecta la validez de la partición. Todas las series se construyen sobre entrenamiento.

3. Series de tiempo construidas (a partir de entrenamiento)

Se construyó la serie obligatoria (total mensual) y se seleccionaron dos categorías de análisis: **(i) Vías de ingreso** (Aérea, Terrestre y Marítima) y **(ii) Países de residencia**, tomando el top 3 según el acumulado de todo el período de estudio 2009–2026 (no solo entrenamiento): El Salvador, Guatemala y Estados Unidos de América. En total se obtienen $1 + 3 + 3 = 7$ series mensuales.

Las series se reindexaron contra el rango fijo de 147 meses de entrenamiento, no contra el primer y último dato de cada subserie, para que los meses sin registro queden en 0 en vez de recortar la serie. Importa en la vía Marítima, sin registros durante 12 meses consecutivos por el cierre de fronteras.

4. Análisis de las series y determinación de estacionariedad

Por serie se presenta: inicio, fin y frecuencia; el gráfico con su descomposición en tendencia, estacionalidad y residuo; ACF y PACF; la fuerza de la estacionalidad y de la tendencia; el diagnóstico de estacionariedad en varianza; y el número de diferenciaciones para alcanzar estacionariedad en media.

ADF y KPSS se usan juntas porque sus hipótesis nulas son opuestas: en ADF la H_0 es que hay raíz unitaria (no estacionaria) e interesa rechazar; en KPSS la H_0 es que la serie es estacionaria e interesa no rechazar. Una serie se declara estacionaria solo si ambas coinciden. Cuando el estadístico KPSS cae fuera del rango tabulado el p-valor se satura, y en esos casos se reporta el límite (>0.1) en lugar del valor saturado.

4.1 Estacionalidad y tendencia

Serie	Fuerza estacional	¿Fuerte?	Pendiente anual	Tendencia
total	0.224	No	+0.0190	positiva
Aérea	0.146	No	-0.0390	negativa
Terrestre	0.245	No	+0.0476	positiva
Marítima	0.395	No	-0.2198	negativa
El Salvador	0.088	No	-0.0786	negativa
Guatemala	0.337	No	+0.0533	positiva
Estados Unidos de América	0.092	No	-0.1258	negativa

Medido sobre la serie transformada ($\log_{1p}$) con el criterio de Hyndman, $1 - \text{Var}(\text{residuo})/\text{Var}(\text{estacional}+\text{residuo})$. Las 7 series quedan por debajo del umbral de 0.64 para estacionalidad fuerte: el patrón anual existe y hay que modelarlo con términos estacionales, pero no domina la variación del residuo y por sí solo no justifica una diferenciación estacional.

La pendiente está en escala logarítmica por año. Es negativa en cuatro series, lo que no indica declive del turismo: el tramo de entrenamiento termina en marzo de 2021 y el ajuste lineal queda dominado por el colapso pandémico. La sección 1.7 muestra la recuperación posterior. Se lee como descriptor del tramo, no como proyección.

4.2 Estacionariedad en varianza y transformación

Serie	corr pre-pandemia	corr train completo	Transformación	corr posterior
total	+0.950	-0.211	$\log_{1p}$	-0.182
Aérea	+0.891	-0.584	$\log_{1p}$	-0.214
Terrestre	+0.944	+0.067	$\log_{1p}$	+0.158
Marítima	+0.964	+0.723	$\log_{1p}$	-0.829
El Salvador	+0.936	+0.149	$\log_{1p}$	+0.124
Guatemala	+0.928	-0.067	$\log_{1p}$	-0.706
Estados Unidos de América	+0.902	-0.324	$\log_{1p}$	-0.133

Se divide cada serie en tramos de 12 meses y se correlaciona la desviación estándar con la media de cada tramo. Sobre el tramo pre-pandemia (2009-01 a 2020-01) la correlación va de 0.89 a 0.96 en las 7 series: la dispersión crece con el nivel y ninguna es estacionaria en varianza.

Sobre el tramo completo esa correlación baja o cambia de signo en seis de las siete series, lo que llevaría a concluir que no hace falta transformar: el colapso de 2020-2021 agrega un tramo de nivel bajo y dispersión alta que rompe la relación y enmascara el diagnóstico. Tras aplicar $\log_{1p}$ la correlación cae al rango -0.83 a $+0.16$. Se usa $\log_{1p}$ y no Box-Cox porque el λ óptimo cambia de signo según se incluya la pandemia, y $\log_{1p}$ admite los ceros exactos de la vía Marítima sin desplazar la serie.

4.3 Análisis por serie

Total mensual de viajeros internacionales

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 237,120.9 **Desv. estándar:** 101,886.5 **Mín-Máx:** 9,779 – 515,820.4




Figura. Total mensual de viajeros internacionales — serie, tendencia, estacionalidad y residuo (train).

Muestra tendencia creciente 2009-2019, colapso pandémico en 2020 y recuperación parcial hacia el corte de entrenamiento (mar-2021). La descomposición aditiva evidencia un componente de tendencia claramente no constante y una estacionalidad anual regular (picos en jul-ago y dic, típicos de temporada alta). El residuo muestra mayor dispersión durante 2020, coherente con la ruptura estructural de la pandemia.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^1 (1-B^{12})^0$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-1.970	0.2998	0.476	0.0470	No
Transformada (log1p)	-2.236	0.1936	0.168	>0.1	No
Transformada + d=1, D=0	-3.100	0.0265	0.041	>0.1	Sí

Sobre el nivel el ADF da $p = 0.2998$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^1 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.224 < 0.64$ (umbral fpp3), y $d = 1$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

Vía de ingreso: Aérea

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 89,141.3 **Desv. estándar:** 29,412.5 **Mín-Máx:** 489 – 157,842.0




Figura. Vía de ingreso: Aérea — serie, tendencia, estacionalidad y residuo (train).

Tendencia creciente sostenida hasta 2019 y estacionalidad anual visible (picos de temporada alta). Cae prácticamente a cero en abr-2020 por el cierre del Aeropuerto La Aurora al tráfico de pasajeros.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^0 (1-B^{12})^0$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-2.364	0.1522	0.233	>0.1	No
Transformada (log1p)	-4.018	0.0013	0.248	>0.1	Sí
Transformada + d=0, D=0	-4.018	0.0013	0.248	>0.1	Sí

Sobre el nivel el ADF da $p = 0.1522$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^0 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.146 < 0.64$ (umbral fpp3), y $d = 0$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

Vía de ingreso: Terrestre

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 139,988.5 **Desv. estándar:** 72,323.9 **Mín-Máx:** 5,715 – 348,626.4



Figura. Vía de ingreso: Terrestre — serie, tendencia, estacionalidad y residuo (train).

Es la serie de mayor volumen y mayor variabilidad absoluta (desv. estándar 72,323.9). Conserva un piso positivo incluso en pandemia, reflejando que el cruce terrestre nunca se cerró por completo (comercio y residentes fronterizos).




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^1 (1-B^{12})^0$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-1.873	0.3451	0.627	0.0202	No
Transformada (log1p)	-1.442	0.5619	0.210	>0.1	No
Transformada + d=1, D=0	-3.460	0.0091	0.101	>0.1	Sí

Sobre el nivel el ADF da $p = 0.3451$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^1 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.245 < 0.64$ (umbral fpp3), y $d = 1$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

Vía de ingreso: Marítima

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 7,991.2 **Desv. estándar:** 6,934.3 **Mín-Máx:** 0 – 29,506.0




Figura. Vía de ingreso: Marítima — serie, tendencia, estacionalidad y residuo (train).

Serie de menor volumen y con un tramo de 12 meses consecutivos exactamente en cero por el cierre de fronteras marítimas, el evento atípico más marcado de las 7 series (16 meses en cero en total, contando algunos previos a la pandemia). Su patrón estacional es menos regular que el de las otras dos vías.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^2 (1-B^{12})^0-$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-0.989	0.7571	0.121	>0.1	No
Transformada (log1p)	4.889	1.0000	0.666	0.0167	No
Transformada + d=2, D=0	-9.634	0.0000	0.255	>0.1	Sí

Sobre el nivel el ADF da $p = 0.7571$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^2 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.395 < 0.64$ (umbral fpp3), y $d = 2$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

País de residencia: El Salvador

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 61,502.0 **Desv. estándar:** 33,698.0 **Mín-Máx:** 0 – 165,263.0




Figura. País de residencia: El Salvador — serie, tendencia, estacionalidad y residuo (train).

Máximo emisor individual; sigue de cerca el patrón agregado de la vía Terrestre, con estacionalidad ligada a fines de semana largos y temporada de fin de año en la región.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^1 (1-B^{12})^0$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-1.781	0.3901	0.588	0.0237	No
Transformada (log1p)	-1.697	0.4325	0.233	>0.1	No
Transformada + d=1, D=0	-5.942	0.0000	0.024	>0.1	Sí

Sobre el nivel el ADF da $p = 0.3901$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^1 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.088 < 0.64$ (umbral fpp3), y $d = 1$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

País de residencia: Guatemala

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 86,951.8 **Desv. estándar:** 40,005.6 **Mín-Máx:** 9,779 – 207,097.0



Figura. País de residencia: Guatemala — serie, tendencia, estacionalidad y residuo (train).

Segunda serie en volumen; como se documentó en 1.2, mezcla flujo aéreo y terrestre y probablemente corresponde en su mayoría a residentes guatemaltecos que regresan del extranjero, por lo que su lectura como "mercado emisor" debe hacerse con cautela.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^1 (1-B^{12})^0$ (der.), 36 rezagos.

Etapa de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-2.091	0.2481	0.667	0.0165	No
Transformada (log1p)	-1.792	0.3847	0.297	>0.1	No
Transformada + d=1, D=0	-2.983	0.0365	0.068	>0.1	Sí

Sobre el nivel el ADF da $p = 0.2481$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^1 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.337 < 0.64$ (umbral fpp3), y $d = 1$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

País de residencia: Estados Unidos de América

Inicio: 2009-01 **Fin:** 2021-03 **Frecuencia:** mensual (MS) **N:** 147 obs. **Media:** 27,955.1 **Desv. estándar:** 11,062.9 **Mín-Máx:** 0 – 54,990.0




Figura. País de residencia: Estados Unidos de América — serie, tendencia, estacionalidad y residuo (train).

Es la única de las 7 series cuya prueba ADF sobre el nivel rechaza la hipótesis nula al 5% ($p = 0.0249$), el único caso que ya en nivel apuntaría a estacionariedad en media sin diferenciar. Es un resultado al filo del umbral: al estabilizar la varianza el p-valor sube por encima del 5% y la serie deja de pasar la prueba, de modo que sí requiere una diferenciación regular. Conviene no leer el 0.05 como una frontera dura cuando el estadístico queda tan cerca.




Figura. ACF sobre el nivel (izq.) y PACF sobre la serie transformada y diferenciada $-\log 1p + (1-B)^1 (1-B^{12})^0$ (der.), 36 rezagos.

Etapas de la serie	ADF estad.	ADF p	KPSS estad.	KPSS p	¿Estacionaria?
Nivel original	-3.122	0.0249	0.191	>0.1	Sí
Transformada (log1p)	-2.861	0.0501	0.316	>0.1	No
Transformada + d=1, D=0	-3.047	0.0307	0.020	>0.1	Sí

Sobre el nivel el ADF da $p = 0.0249$ y la ACF decae lentamente con oscilación anual. La especificación que alcanza estacionariedad es $\log 1p + (1-B)^1 (1-B^{12})^0$, donde $D = 0$ porque fuerza de estacionalidad $0.092 < 0.64$ (umbral fpp3), y $d = 1$ por el criterio conjunto ADF+KPSS. En la última fila de la tabla ambas pruebas coinciden, lo que confirma que las diferenciaciones son suficientes y no excesivas.

4.4 Resumen: transformación y órdenes de integración por serie

Serie	Transf.	d	D	s	Fuerza estac.	Pendiente anual	Estacionaria
total	log1p	1	0	12	0.224	+0.0190	Sí
Aérea	log1p	0	0	12	0.146	-0.0390	Sí
Terrestre	log1p	1	0	12	0.245	+0.0476	Sí
Marítima	log1p	2	0	12	0.395	-0.2198	Sí
El Salvador	log1p	1	0	12	0.088	-0.0786	Sí
Guatemala	log1p	1	0	12	0.337	+0.0533	Sí
Estados Unidos de América	log1p	1	0	12	0.092	-0.1258	Sí

Las 7 series requieren la misma transformación, lo que simplifica compararlas: todas se modelan en escala logarítmica y las predicciones se revierten con `expm1` antes de calcular métricas de error, para que queden en viajeros. Ninguna requiere diferenciación estacional y la regular va de 0 a 2. Esta tabla es el punto de partida para identificar los órdenes p y q .

5. Generación de modelos

Se ajustaron cinco familias por serie: SARIMA, Holt-Winters, suavizamiento exponencial simple, seasonal naive y Prophet. Todas se estiman sobre la serie transformada con $\log_{10}$ y el pronóstico se revierte a viajeros antes de compararlo, de modo que las métricas de error queden en la escala original.

Los órdenes de SARIMA se buscaron por grid sobre SARIMAX minimizando AIC, no con `auto_arima`: `pmdarima` no es compatible con la versión de `numpy` del entorno. El grid es equivalente en criterio, con la ventaja de que `d` y `D` quedan fijados por el análisis de estacionariedad de la sección 4 en lugar de re-estimarse.

5.1 Elección de p , d y q

d y D vienen de la sección 4. Para p y q el grid se acotó leyendo ACF y PACF de las series ya diferenciadas: la PACF entra en las bandas de confianza tras uno o dos rezagos, lo que acota $p \leq 2$, y la ACF muestra el mismo comportamiento para q . Los picos residuales en los rezagos 12 y 24 justifican mantener el término estacional aunque $D = 0$. Dentro de ese espacio se eligió la combinación de menor AIC.

Serie	(p,d,q)	(P,D,Q,s)	AIC	BIC	Residuos indep.
total	(1,1,2)	(1,0,1,12)	72.1	89.3	No
Aérea	(1,0,1)	(1,0,1,12)	178.9	193.4	No
Terrestre	(0,1,1)	(1,0,1,12)	124.3	135.8	Sí
Marítima	(0,2,2)	(1,0,1,12)	551.9	566.3	Sí
El Salvador	(2,1,2)	(0,0,1,12)	438.4	455.6	Sí
Guatemala	(1,1,0)	(1,0,1,12)	-7.3	4.2	No
Estados Unidos de América	(1,1,2)	(1,0,1,12)	395.4	412.7	Sí

El orden regular varía con la serie: la vía Aérea es la única con $d = 0$ y la Marítima necesita $d = 2$, coherente con su tramo en cero. En El Salvador el grid eligió un término estacional sin componente autorregresivo, a diferencia del resto.

5.2 Parámetros de los demás modelos

Modelo	Parámetros ajustados	Lectura
Holt-Winters	tendencia y estacionalidad aditivas, periodo 12; $\beta = 0$	la tendencia no aporta
Suav. exponencial	α entre 0.61 y 1.00 según la serie	se ancla al último valor
Seasonal naive	estación de 12 meses, sin parámetros a estimar	piso de comparación
Prophet	estacionalidad anual; semanal y diaria desactivadas	solo aplica la anual

Dos parámetros merecen atención. En suavizamiento exponencial, α cercano a 1 en cuatro series significa que el modelo pondera casi exclusivamente la última observación y descarta la historia. En Holt-Winters, $\beta = 0$ en las siete series indica que el optimizador anuló el componente de tendencia: con el tramo de entrenamiento terminando en plena pandemia, una tendencia lineal no mejora el ajuste.

5.3 Comparación por AIC, BIC y residuos

Seasonal naive y Prophet no reportan AIC ni BIC porque no se estiman por máxima verosimilitud; sus celdas aparecen vacías en las tablas. Los valores de AIC tampoco son comparables entre series distintas, porque cada una se ajusta en su propia escala logarítmica; solo tienen sentido dentro de una misma serie.

La prueba de Ljung-Box sobre los residuos es el criterio más exigente: solo 6 de las 35 combinaciones serie-modelo dejan residuos indistinguibles de ruido blanco, y cinco de ellas son SARIMA. En el resto queda estructura sin capturar, lo que era esperable: ningún modelo estimado sobre 2009-2021 puede absorber un quiebre del tamaño de la pandemia.

6. Predicción sobre el conjunto de prueba

Cada modelo pronostica los 63 meses del conjunto de prueba (2021-04 a 2026-06). El pronóstico se revierte de log1p a viajeros y sobre esa escala se calculan MAE y RMSE, de modo que el error sea interpretable en personas. El criterio de selección es RMSE, que penaliza más los errores grandes.

Serie	SARIMA	Holt-Winters	Suav. exponencial	Seasonal naïve	Prophet	Mejor
total	257,979	216,458	194,791	253,203	284,419	Suav. exponencial
Aérea	73,150	52,231	41,368	79,077	92,231	Suav. exponencial
Terrestre	181,597	164,245	156,310	176,653	192,179	Suav. exponencial
Marítima	1,732	1,732	1,732	1,732	1,645	Prophet
El Salvador	117,605	111,527	104,531	117,633	117,603	Suav. exponencial
Guatemala	53,136	54,636	55,571	58,176	57,646	SARIMA
Estados Unidos de América	44,576	37,645	28,953	44,196	46,906	Suav. exponencial

RMSE en viajeros por serie y modelo.

Serie	SARIMA	Holt-Winters	Suav. exponencial	Seasonal naïve	Prophet	Mejor
total	238,984	196,957	175,088	235,731	266,995	Suav. exponencial
Aérea	68,720	48,043	36,109	75,104	89,017	Suav. exponencial
Terrestre	165,279	148,023	140,428	160,013	176,160	Suav. exponencial
Marítima	859	859	858	858	784	Prophet
El Salvador	107,540	101,044	94,064	107,474	106,870	Suav. exponencial
Guatemala	35,038	44,222	46,681	41,033	29,032	Prophet
Estados Unidos de América	41,135	34,198	25,115	41,168	43,724	Suav. exponencial

MAE en viajeros por serie y modelo.




Figura. Total mensual de viajeros internacionales — pronóstico de cada modelo frente al valor real.




Figura. Vía de ingreso: Aérea — pronóstico de cada modelo frente al valor real.




Figura. Vía de ingreso: Terrestre — pronóstico de cada modelo frente al valor real.




Figura. Vía de ingreso: Marítima — pronóstico de cada modelo frente al valor real.




Figura. País de residencia: El Salvador — pronóstico de cada modelo frente al valor real.




Figura. País de residencia: Guatemala — pronóstico de cada modelo frente al valor real.




Figura. País de residencia: Estados Unidos de América — pronóstico de cada modelo frente al valor real.

6.1 Qué tan bien predicen los modelos

Por RMSE los ganadores se reparten así: simple_exponential en 5; prophet en 1; sarima en 1. El suavizamiento exponencial simple gana en la mayoría de las series, y en 4 de ellas el seasonal naive iguala o supera a SARIMA.

Eso no significa que los modelos simples capturen mejor la dinámica. El entrenamiento termina en marzo de 2021, en el piso de la pandemia, así que los modelos con estructura estacional proyectan la continuación de ese nivel, mientras el suavizamiento exponencial —con α cercano a 1— se ancla al último valor y queda más cerca de una serie que empieza a subir. El conjunto de prueba cubre justamente la recuperación y el quiebre de 2023: ningún modelo entrenado en ese tramo podía anticipar el rebote. Los errores deben leerse en ese contexto y no como medida de la calidad del ajuste.

Las dos métricas coinciden en casi todas las series, con una excepción — Guatemala: mejor MAE prophet, mejor RMSE sarima. La diferencia aparece porque el RMSE penaliza más los errores grandes: el modelo con mejor MAE acierta más en el mes típico, pero falla peor en los meses extremos. Se reporta el ganador por RMSE por consistencia con el resto del análisis.

7. Análisis comparativo

Se comparan las series dentro de cada categoría con cuatro criterios: fuerza de la estacionalidad, pendiente de la tendencia, volatilidad relativa e impacto de la pandemia. La volatilidad se mide con el coeficiente de variación (desviación estándar sobre media) y no con la desviación cruda, porque las series tienen volúmenes muy distintos y la desviación absoluta solo reflejaría el tamaño.

Las cifras de esta sección se calculan sobre la serie en nivel, mientras que las de la sección 4 están en escala logarítmica; los valores no son directamente comparables entre secciones, aunque el orden relativo entre series se mantiene. El umbral de 0.64 mencionado en la sección 4 aplica solo a la escala logarítmica.

7.1 Vías de ingreso

Serie	Fuerza estac.	Pendiente anual	CV	% de 2019 en 2020	Meses en 0
Aérea	0.558	2,237	0.330	27.7%	0
Terrestre	0.387	12,373	0.517	26.4%	0
Marítima	0.614	286	0.868	32.1%	12

- **Mayor estacionalidad:** Marítima (0.614).
- **Mayor tendencia de crecimiento:** Terrestre (12,373 viajeros/año).
- **Mayor volatilidad:** Marítima (0.868).
- **Más afectada por la pandemia:** Terrestre, con una caída de 73.6% en 2020 frente a 2019.

7.2 Países de residencia

Serie	Fuerza estac.	Pendiente anual	CV	% de 2019 en 2020	Meses en 0
El Salvador	0.318	5,398	0.548	25.1%	5
Guatemala	0.534	6,946	0.460	29.8%	0
Estados Unidos de América	0.703	541	0.396	26.3%	5

- **Mayor estacionalidad:** Estados Unidos de América (0.703).
- **Mayor tendencia de crecimiento:** Guatemala (6,946 viajeros/año).
- **Mayor volatilidad:** El Salvador (0.548).
- **Más afectada por la pandemia:** El Salvador, con una caída de 74.9% en 2020 frente a 2019, con 5 meses consecutivos en cero.

7.3 Hallazgos útiles para el INGUAT

- La vía más volátil en términos relativos (CV) es Marítima, no necesariamente la de mayor desviación absoluta: para planificar capacidad (personal en frontera, slots aéreos) importa más esta inestabilidad relativa que el volumen bruto.
- Por caída porcentual anual, Terrestre fue la vía más golpeada por la pandemia (caída de 74% en 2020 vs. 2019).
- Aparte de lo anterior, Marítima es la única vía que estuvo completamente cerrada durante la pandemia (12 meses consecutivos en cero): aunque su peso relativo en el total sea menor, es la que evidencia con más

claridad un cierre total del canal (no solo una baja de demanda) y la que un plan de contingencia ante el cierre de fronteras debería priorizar.

- Guatemala aparece con la mayor pendiente de crecimiento entre los tres principales países de residencia, pero esa serie corresponde mayoritariamente a residentes guatemaltecos que regresan del extranjero (ver hallazgo del análisis exploratorio), no a un mercado turístico extranjero: no es una serie sobre la que tenga sentido recomendar promoción internacional.
- El Salvador (31.0% del total histórico) domina como mercado emisor casi en su totalidad por vía terrestre: si la promoción del INGUAT se diseña con el mismo enfoque que para el turismo aéreo de larga distancia, está apuntando mal a su mercado más grande.
- En Total mensual de viajeros internacionales, Vía de ingreso: Terrestre, Vía de ingreso: Marítima, País de residencia: Estados Unidos de América, el modelo seasonal naïve iguala o supera a SARIMA en el conjunto de prueba: dado que train solo vio la caída pandémica y test es toda la recuperación (más el quiebre metodológico de 2023), ningún modelo entrenado en ese tramo podía anticipar el rebote — el hallazgo en sí (que el quiebre estructural es más grande que lo que cualquier modelo de serie de tiempo puede capturar) es más útil para INGUAT que la predicción puntual.

8. Conclusiones

- El conjunto de datos tiene dos quiebres que condicionan todo el análisis: la pandemia y el cambio metodológico de 2023. Turista + Excursionista (89.3% del total) es la única combinación comparable en todo el período.
- Ninguna de las 7 series es estacionaria en varianza; las 7 se estabilizan con log1p. El diagnóstico solo es válido si se hace sobre el tramo pre-pandemia: medido sobre el entrenamiento completo, el colapso de 2020 enmascara la relación entre dispersión y nivel.
- La estacionalidad es visible en las siete series pero no domina la varianza del residuo, así que se modela con términos estacionales sin diferenciación estacional. La diferenciación regular necesaria varía por serie.
- La prueba de Ljung-Box deja residuos independientes en pocas combinaciones serie-modelo, casi todas SARIMA. El resto conserva estructura sin capturar.
- Sobre el conjunto de prueba los modelos simples superan a los estructurales, porque el entrenamiento termina en el piso pandémico y no contiene información sobre la recuperación. El hallazgo es que el quiebre estructural excede la capacidad de un modelo univariado, no que los modelos simples sean mejores.
- Para el INGUAT, el valor del análisis está en la caracterización de las series —volatilidad relativa, canales que cerraron por completo, composición real de cada mercado emisor— más que en la predicción puntual sobre un período con un quiebre de esta magnitud.